



金蝶

2025全球创见者大会
GLOBAL CHANGEMAKERS CONFERENCE 2025

AI智能体在未来产业创新 上的前沿应用与发展趋势

邱维明 亚太人工智能学会常务副秘书长

2025.11.04



目录

一、人工智能产业宏观趋势

二、Agent vs Agentic AI

三、近期Agentic AI 行业动态

四、全球智能体创新创业公司

五、正在发生的智能体技术创新

六、未来智能体技术突破方向

七、智能体行业应用

八、Agentic AI重新定义协同办公

九、Benchmark、数据集、评估流程、示例



十、安全与风险治理与企业战略建议

宏观趋势：从AI模型时代迈向Agentic时代


从模型智能到行为智能，大模型（LLM）阶段：关注“理解与生成”

智能体（Agentic AI）阶段：关注“感知—决策—行动—学习”闭环

Agent = Model + Memory + Action + Reflection + Evolution




Agent vs Agentic AI



核心模块——感知（Perception）、推理（Reasoning）与行动（Action），逐步扩展到更高级的组件，如专用智能体（Specialized Agents）、高级推理与规划（Advanced Reasoning & Planning）、持久记忆（Persistent Memory）以及编排层（Orchestration）。多智能体协作（Multi-Agent Collaboration）、系统协调（System Coordination）、共享上下文（Shared Context）和任务分解（Task Decomposition），分层模块化向分布式、自适应的Agentic AI 智能转变。

局限性对比：Agent vs Agentic AI



- 缺乏因果推理能力；
- 受大语言模型（LLM）固有缺陷限制（如幻觉现象、浅层推理等）；
- 能动性不足（在自主性、主动性等方面存在缺陷）；
- 长期规划与恢复能力薄弱。

- 多智能体之间的错误级联效应；
- 协调失效与通信不稳定；
- 涌现行为导致的系统不稳定性；
- 可扩展性受限；
- 可解释性不足；
- 缺乏统一的架构与通信协议；
- 跨任务的调度复杂性；
- 因果一致性难以保障。

Agentic AI 市场

正经历前所未有的爆发式增长。多家权威机构预测：


规模：2024年全球AI智能体市场规模约52.9亿美元，预计2030年达460-470亿美元，年CAGR复合增长率40+%

资本流向

北美：最大资金池与企业客户基数，VC、云厂与并购活跃。美国私募/风投对 later-stage 集中度高。

欧洲：2025 年活跃，重点在隐私合规与企业效率工具，部分早期基金加大部署。

中国更多偏向出海应用层服务；以色列在中后台技术（强化学习、规划模块）持续孵化高技术初创。



美国Agentic AI产业生态分层图（2025版）

层级	关键特征	代表公司
1. 应用生态与市场层	企业服务、消费者体验、开发者社区	OpenAI GPTs、Lovable Studio、Genspark Marketplace、Replit Agents
2. 行业垂直层 (Vertical Agents)	金融、医疗、教育、制造、能源、法律、媒体等	多个新兴创业公司与企业内部Agent化
3. 体验与协同中台层 (Agentic Platform)	多Agent协同、上下文工作流、反思学习	Lovart EvoAgents、Anthropic Reflexive System、Genesis World、MemGPT
4. 智能体操作系统层 (Agent OS)	架构标准化、任务调度、工具调用、长记忆	Lovable、Gensparks、Manus、LangChain、AutoDevin、CrewAI
5. 底层模型与计算层	多模态大模型、可微推理、强化学习、算力服务	OpenAI (GPT-o3)、Google Gemini 2.5、Anthropic Claude 3.5、xAI Grok、Mistral

Web应用与智能体系统产业发展比较




Fig. 11. Comparison of the evolution of web applications and agent systems

Agentic AI商业模式创新



- 智能体即服务（AaaS）按需租用AI智能体能力
- 协作式AI平台：多智能体协作完成复杂任务
- 个性化AI助手：为个人和企业提供定制化智能服务
- AI智能体市场：智能体能力的交易和共享平台

Agentic AI规模化应用拐点


2025年被业界普遍视为AI智能体大规模应用的“拐点时刻”。
预计到2028年，33%的企业软件应用将集成AI智能体功能。
超过15%的日常工作决策将由AI智能体自主完成。

行业渗透路径：

第1波（2024—2025）： 客户服务、数据分析、内容创作

第2波（2025—2026）： 金融风控、医疗诊断、教育个性化

第3波（2026—2027）： 制造业智能化、供应链优化、城市管理



Agentic AI对传统产业的变革影响

产业结构重塑： AI智能体将深刻改变传统产业的运作方式，预计到2028年，AI智能体的应用有望使组织运营成本降低40%，营业收入提升20%。

就业结构变化：

- 岗位替代：重复性、规则化的工作将面临替代
- 岗位创造：AI智能体开发、训练、维护等新岗位需求增长
- 技能要求转变：对创造性、战略性、情感交流能力的需求增加



核心特征：Agentic AI产业演化趋势


趋势	描述	代表性系统
1. 从应用驱动到生态驱动	Agent不再是单点App，而是行业生态的核心执行层	OpenAI GPT Store、Lovable EvoWorld
2. 从Prompt到Policy演化	模型不再仅靠指令微调，而是具备策略级自学习	DeepMind Self-Improving Models
3. 从单智能体到多智能体协同	出现多智能体社会系统，实现自治任务分工	Genesis、Genspark Agents
4. 从虚拟智能到具身智能	智能体进入机器人、汽车、制造、物流等领域	Tesla Optimus、Figure 03、Sanctuary
5. 从模型应用到产业系统共演化	Agent嵌入产业流程成为生产力单元	Lovart Industrial Agents、Microsoft Copilot Stack

Agentic AI技术创新

十种新兴的架构与算法解决方案：

- 检索增强生成 (RAG)
- 工具增强推理 (函数调用)
- 智能体反馈闭环：推理、行动、观察
- 记忆架构 (情景记忆、语义记忆、向量记忆)
- 多智能体协同与专业化角色
- 反思与自我批判机制
- 程序化提示工程流程
- 因果建模与基于仿真的规划
- 监控、审计与可解释性流程
- 治理感知架构 (责任追踪与角色隔离)


这些方法用于提升两个范式在可靠性、可扩展性与可解释性方面的表现



Agentic AI技术突破方向：

Gartner预测，AI智能体被列为2025年十大战略技术趋势之首。

- 多模态能力融合：结合文本、图像、音频、视频的多模态AI智能体将成为主流
- 自主决策能力提升：从简单的任务执行向复杂的决策制定演进
- 协作能力增强：多智能体之间的协作和通信将更加智能和高效
- 边缘计算集成：AI智能体将与边缘计算深度融合，实现更快的响应速度



多智能体演化方法从单个LLM实例化出三个交互式角色（提议者、求解者和评判者），形成一个闭环的自改进机制。提议者生成新问题，求解者尝试回答这些问题，评判者评估两者，并提供通用领域的奖励信号。评判者奖励求解者。正确的推理，而提议者则从评判者那里获得质量奖励，以及当求解者失败时增加的难度奖励，从而形成一个对抗性的协同演化过程，持续提升模型的推理能力。

智能体发展概述

目前智能体应用主要路线发展：

- Deep Research智能体，它充当“大脑”，擅长复杂的推理和分析；
- GUI智能体，它充当“眼睛和手”，模拟人类与图形环境的交互。
- 具身智能与人形机器人

General Domain



Memory
Mechanism



Model-Agent
Co-Evolution



Curriculum-Driven
Training

Specific Domain



Coding



GUI



Financial



Medical



Education



Others

未来十年的Agentic AI战略结构（2025 – 2035）

阶段	时代主题	技术核心	应用核心
2025 – 2027	Agent化操作系统时代	长期记忆、反思推理、任务编排	知识工作自动化
2027 – 2030	自我进化智能体时代	自学习、自组织、多Agent协同	跨领域任务协同
2030 – 2035	智能体产业网络时代	自我演化生态、具身智能融合	产业链自治优化

AI Strategy Framework



Aligned AI Vision



Ethics + Governance



Opportunity Identification



Roadmap & Goals



Organization Enablement

10月智能体产业5个重要的事件


- OpenAI 在 DevDay 发布 AgentKit，定位为构建/部署/优化 agents 的工具链（强调开发者体验、部署与监控）。
- Google 把 Agentspace 整合/升级为 Gemini Enterprise：面向企业的 agent 平台、连接器与低代码创建体验，强调安全与集成（Jira/Confluence/Office 等）。
- Anthropic 发布 Claude Skills / Agent SDK / Sonnet/Haiku 系列（加强 coding/工具使用能力与“技能包”机制），把 agent 特定能力模块化。
- 10月23号，AI应用公司LiblibAI宣布完成1.3亿美元B轮融资，由红杉中国、CMC资本及一战略投资方联合领投，老股东顺为资本、源码资本、渙策资本均超额增持，联想创投等机构参与投资。融资完成后，LiblibAI将加速全球化布局，打造全球创作者共创的多模态内容生态。
- Genspark 正在进行大额融资（> 2亿美元谈判），市场对专注 agent 平台/垂直场景解决方案的公司仍有强烈资本兴趣。

Google Cloud+新兴玩家与独角兽（Lovart、Genspark、Manus 、Lovable等）正在用“低代码/可组合 agent + 垂直化能力”实现快速商业化，显示出社区化+平台化+垂直解决方案是短期内最容易商业化的路径。


技术上有三条决定未来 2 - 5 年智能体成败的主线：

- “Computer-use / tool use” agent 能安全、稳定地操控软件 / 浏览器 / API；
- 多 agent 协作与编排（orchestration）；
- 领域化技能包（Skills/SDKs）与可治理的权限模型。

Anthropic、Google、OpenAI 的近期产品正围绕这三点发力。




头部通用Agent网页流量（单位：万用户）



Liblib.AI Lovart


Lovart 宣称自己是“世界上第一个设计 AI 智能体 (Design AI Agent)”——即不仅是一个工具，而是一个可以“对话 + 理解需求 + 执行设计流程”的智能体。是一个典型“智能体”在创意设计领域的落地案例：它把“自然语言交互 + 多模态生成 + 流程自动化”组合起来，形成可实际操作的设计助手 / 执行者。




1. 流量来源国别Top5 (7月)

国家/地区		流量份额	
	中国	17%	
	美国	17%	
	巴西	11%	
	印度	8%	
	印尼	6%	


2. 社交流量比例 (7月)



3. 推特近7日新发布帖子：520



AI Agent Architecture Flow



Agentic AI 模型能力内化

Agentic AI正从外部流水线转向模型原生，推理、记忆与行动等能力被内化到模型策略中，借助强化学习把感知与行动打通，让静态模型变成可从环境互动中学习的目标驱动体。

LLM + RL + Task 正在成为当下AI应用的“方法论奇点”，通过预训练→后训练→推理的循环，把算力持续转化为智能。

未来不仅是更高自治，更是模型与环境深度耦合/共生；这种范式迁移也意味着从“构建会用智力的系统”走向“通过经验自进化的智能”。




Fig. 1. From Pipeline to Model-native: RL-driven evolution of agentic capabilities and applications.

Agentic AI：对齐LLM 强化学习 任务

新范式模型原生则强调通过端到端训练把规划、工具使用与记忆内化进模型参数，让LLM成为主动决策者。

这种范式转变的核心驱动力正是大规模强化学习（RL）用于LLM训练，使得从“SFT/偏好优化”转向结果驱动的RL（如GRPO、DAPO等），从而形成了统一训练图景“LLM + RL + Task”。




Fig. 10. A roadmap for the model-native internalization of agentic capabilities.

人工智能范式转变：从人为设计规则到数据驱动学习




Fig. 9. Paradigm shift in AI: from *human-designed rules* to *data-driven learning*.

人工智能范式转变：从人为设计规则到数据驱动学习

- L0（无自主性）：所有工作完全由人类手动完成。
- L1（辅助）：数据智能体作为问答机，能根据提问生成代码片段或分析，但无法动态执行或与环境交互，需要人类手动整合验证。
- L2（部分自主）：数据智能体获得感知并交互数据环境（如DBMS、代码解释器、API）的能力，在人类设计好的流程中自主执行特定任务。
- L3（条件自主）：数据智能体成为任务的「主导者」并开始承担数据相关任务的主要责任，不再局限于人类与定义的流程和特定的任务，能自主编排端到端的流程来解决多样化、综合性的数据相关任务，人类角色退居为「监督员」。
- L4（高度自主）：数据智能体无需人类监督和任务指令，即持续监控数据环境，主动发现有价值的问题并可靠的解决。人类变为「旁观者」，只负责接收最终洞察。
- L5（完全自主）：终极愿景，数据智能体成为真正的数据科学家，不仅能应用现有方法，更能自主创造新算法、新范式，实现真正的创新，推动数据管理、准备和分析的边界。




Fig. 1: An Overview of Data Agents.

L3 及更高等级的数据智能体挑战

- 受限的工作流编排：如何超越预定义的算子和工具池？
- 不完整的数据生命周期覆盖：如何让数据智能体精通从底层系统管理到顶层分析的全链路？
 - 高级推理能力缺失：如何让数据智能体具备整体反思，长远规划和权衡能力（比如权衡前期数据清洗的开销和潜在的分析阶段的收益）？
 - 动态环境适应性不足：如何让数据智能体在数据、需求不断变化的环境中动态适应、自我进化？





Fig. 2: Representative Data Agents Across Different Levels.

大语言模型的实时动态更新问题

大语言模型本质是静态的，无法在面对新任务、不断进化的知识领域或动态交互环境时调整内部参数，已成为一个关键瓶颈，需能实时进行自适应推理、行动和进化的智能体。



自我进化智能体分类、代表性方法和系统

类别	特征描述	核心机制	代表模型/系统
1. 自我优化型 (Self-Improving Agents)	智能体基于任务执行反馈自动优化策略或 Prompt	RLHF、RLAIF、Meta-RL、自适应 Prompt 优化	DeepMind <i>Self-Improving Embodied Models (2024)</i> 、OpenAI AutoGPTX、Anthropic <i>Claude Feedback Loops</i>
2. 自我重组型 (Self-Evolving Architecture Agents)	智能体具备可重构模型结构、模块进化能力	Neural Architecture Search (NAS)、Mixture-of-Experts 自演化	Google Gemini System Adaptation、Meta ESM-3 Evolutionary Framework
3. 自我反思型 (Self-Reflective Agents)	能进行元认知反思、自评和迭代修正	Reflexion、Tree-of-Thought、Self-Critique Loops	Reflexion (Yang et al., 2023)、GPT-SoM (Self-Organizing Memory)
4. 自我编程型 (Self-Reprogramming Agents)	智能体能生成并执行新的代码或工具调用策略	Code Interpreter、AutoDev、EvoPrompt、DSL 自演化	OpenDevin、Lovable AutoCoder、SWE-Agent
5. 自我记忆型 (Memory-Evolving Agents)	动态构建与重组长短期记忆结构	Vector DB + Episodic Memory + Memory-Augmented RL	MemoryBank (MemGPT)、Memories.ai、Genspark Memory Graph
6. 自我协同型 (Multi-Agent Co-Evolution Systems)	多智能体通过竞争/合作共同进化	Co-Evolutionary Reinforcement Learning、Role-Agent Adaptation	Meta's CICERO 2、Genesis Multi-Agent World、Lovart Agent Studio
7. 自我生长型 (Self-Growing Embodied Agents)	在物理或虚拟环境中通过交互学习进化	Embodied RL、World Model + Reward Evolution	Tesla Optimus RL-World、Google RT-X、Figure 03





Figure 2: Taxonomy of self-evolving agents, in which agents are analyzed along the *what*, *when*, *how*, and *where* dimensions, with selected representative methods and systems annotated at each leaf node.

Agentic AI 智能体个性化

个性化智能体已成为研究界一项至关重要且日益重要的目标。关键挑战是智能体能够准确捕捉并适应用户在长期互动中的独特行为模式或偏好。准确解读用户意图，并有效构建用户画像。

目前，在个性化规划与执行方面也存在重大挑战，需要有效的长期记忆管理、外部工具集成以及个性化生成能力提升，确保输出始终与个人用户的事实和偏好保持一致。确保自进化智能体不会无意中强化或加剧现有的偏见和刻板印象




技术层小结

- 基础模型层（LLM / multimodal）趋势：更小/更快的“computer-use”模型（例：Gemini 2.5 Computer-Use、Anthropic 的 Sonnet/Haiku），目标是实时交互并安全操控工具。
- 工具/插件接入层（Tooling）包括浏览器自动化、API 适配器、RAG（检索增强生成）管线、表格/数据库操作插件。OpenAI/Anthropic/Google 都在扩展 SDK 与 connector。
- 能力封装层（Skills / Plugins / Agents）将领域能力模块化（如会计报表技能、药物检索技能、客服知识库技能）以实现可复用、可审计、可测试。Anthropic 的 Skills 是典型实践。
- Anthropic编排/协作层（Orchestration）多智能体协作、任务拆解（Task decomposition）、错误回滚、审批流、人机混合 loop。行业正从“单 agent 问答”转向“多 agent 协作完成流程”。（研究与产品同时推进）
- 治理/审计/安全层权限边界、行动白名单、可解释性日志、合规 RAG 审计。企业化平台（Gemini Enterprise、AgentKit）把治理做为首要差异化能力。

技术结论：未来 12 - 36 个月，谁能把“computer-use 能力 + 可插拔 Skill 市场 + 企业级治理”做得既可用又可控，谁就能掌握 B2B 市场关键入口。

Agentic AI 未来充满希望的发展方向

- 构建开放式模拟环境：为Agent提供一个可以自由探索、试错和进化的“数字沙盘”。
- 推进工具的自适应与自创造：让工具与Agent共同进化，形成强大的“人机”共生体。
- 开发面向真实世界的评估基准：建立能够进行长期、交互式评估的测试平台。
- 探索兼顾效能与效率的优化算法：设计能够在资源受限下部署的高效多智能体系统。



金融Agentic AI

投资与量化研究 (Buy-side / Sell-side Research Agent)

应用：自动化情报抓取、因子发现、策略回测、全天候事件监测与舆情合成，自动生成投资备忘与交易信号。

价值：大幅提速研究覆盖、降低人力成本、实现“全天候Alpha挖掘”。

技术：大模型（推理+计划）、Wide Research 多 agent 编排、回测引擎、数据校验层、向量记忆。

阻碍/治理：数据合规、内幕/市场操纵风险、模型过拟合与群体拥挤。

时间窗：短中期（1 - 3 年广泛试点；3 - 5 年成熟）。

KPI/落地切入：覆盖率（研究主题/公司数）、信号精准度、信息检索速度；建议先做“研究助理”替代低阶任务并加入人机复审。

Benefits of Agentic AI in Finance



Slow reconciliations result in delayed close

Agents reconcile 10× faster with ~99% accuracy → cleaner books



Forecasts go stale quickly

Agents update in real-time → faster treasury action



Finance is buried in manual tasks


Agents handle routine work → teams focus on strategy

医疗Agentic AI

AI智能体正在改变传统的诊断和治疗模式：

- 药物研发加速：AI智能体能够分析分子结构、预测药物相互作用，大幅缩短新药研发周期。麦肯锡报告显示，AI在药物研发领域的影响力约75%来自加速新产品候选方案的生成麦肯锡。
- 智能诊断辅助：通过分析医学影像、病历数据和症状描述，AI智能体能够辅助医生做出更准确的诊断。
- 个性化治疗方案：基于患者的基因信息、病史和生活习惯，制定个性化的治疗计划。


Applications of **Agentic AI** in Healthcare



教育Agentic AI

AI智能体正在重塑教学模式：

- 个性化学习助手：根据学生的学习进度、知识掌握情况和认知特点，定制个性化的学习路径和内容推荐。
- 智能批改系统：自动批改作业和试卷，提供详细的反馈和改进建议。
- 虚拟教学助理：协助教师进行课程设计、学生管理和教学效果评估。




制造业Agentic AI

AI智能体正推动着工业4.0的深入发展：

- 预测性维护：通过分析设备运行数据，预测潜在故障，提前进行维护。
- 质量控制：实时监控生产过程，自动识别和纠正质量问题。
- 供应链优化：协调供应商、库存和物流，实现供应链的智能化管理。

5 use cases of agentic AI in manufacturing




Agentic AI协同办公应用

为什么协同办公的“效率困境”正在倒逼Agentic AI登场

- 过去十年数字化 → “系统上云”
- 现在五年智能化 → “智能下沉到每一个岗位”
- 企业办公的“中台化”架构遭遇瓶颈：工具碎片化、审批流冗余、知识沉没
- 这正是 Agentic AI 的入口条件：从“人操作系统” → “人+智能体协同系统”
- 协同办公的下一范式革命，不再是应用堆叠，而是“Agent在组织内的协作分工体系重构”。

Agentic AI in Collaboration and Workflow Optimization



AI协同办公应用场景结构（典型“效率断点”）

场景	症结	典型现象
会议协同	信息冗余、任务落地率低	会后纪要无跟踪、责任模糊
流程审批	流程复杂、审批层级多	大量人工催办、无智能优先级
跨部门项目协作	数据来源多、角色权限复杂	PM手动整合数据、任务跟踪低效
知识管理	文件堆积、搜索难	组织记忆缺失、重复劳动
客户协作	CRM割裂、多端沟通难整合	销售/客服信息不同步、流失难察觉
绩效与汇报	报表重复、缺乏智能洞察	KPI考核与执行偏离

这些“断点”本质上都是上下文传递不畅和认知负荷过高的问题。

这正是 Agentic AI 能够介入的核心突破口。

AI协同办公应用场景宏观结构性矛盾

维度	现状	深层问题
人力结构	劳动密集型岗位占比仍高，知识型岗位扩张迅速	大量“低效中台岗位”与“重复劳动岗位”并存，自动化水平低
管理层级	层级多、审批链长	“管理者依赖表格”，信息孤岛严重，决策周期长
数字化基础	企业普遍上云、用钉钉/飞书/企业微信	数据碎片化、跨系统协同弱、流程无法真正闭环
激励机制	绩效导向KPI，短期结果驱动	无法衡量知识工作与协同效率，导致“多做多错”文化
工具生态	SaaS工具众多（OA、CRM、ERP）	工具间缺乏“认知统一”，需要大量人工衔接与验证

协同办公中的 Agentic AI 需求六大类

需求类型	核心价值	典型应用Agent
1. 智能任务编排 Agent	自动理解会议纪要、分配任务、设置提醒、监控进度	会议纪要 → 行动项 → 项目进度仪表盘
2. 审批自动化 Agent	跨系统读取表单、判断流程逻辑、智能路由审批	费用报销、采购审批自动流转
3. 知识聚合 Agent	自动抓取团队文件、对话、邮件，生成“语义知识图谱”	自动生成 FAQ、行业洞察、项目档案
4. 协作沟通 Agent	理解多方意图，充当数字协调者	跨部门任务沟通、信息同步提醒
5. 决策助理 Agent	汇总多系统数据、生成洞察报告	财务预测、项目健康度分析、KPI对齐
6. 个体生产力 Agent	个人层面的语义助手	自动生成日报、智能排会、总结周报
这些Agent最终都会接入企业常用协同生态：如云之家→ 构成一个 “Agentic AI 协同办公中台”。		

全球趋势与生态观察

公司	战略	特点
Microsoft 365 Copilot	内嵌企业生态	文档 + 邮件 + Teams 联动
Google Gemini for Workspace	智能会议 + 任务总结	搜索+Gmail+Calendar整合
Notion AI / Coda	面向中小团队	模板化协作Agent
Salesforce Agentforce	CRM导向Agent生态	与客户数据强绑定
中国：金蝶、钉钉、飞书、企微	正在构建企业操作系统层的Agent生态	与业务流深度结合，场景落地空间最大

- 未来 3 年：协同办公AI 市场 CAGR >35%;
- 从“功能性插件AI” → “组织级Agent生态”;
- 谁掌握了“工作语境理解 + 企业数据治理”两大核心，就能建立平台壁垒。

协同办公Agentic AI 发展阶段预测

阶段	特征	代表创新方向
2025 – 2026	Agent化初期，智能体嵌入企业应用	会后任务Agent、审批Agent
2026 – 2027	组织智能化，Agent形成协同网络	多Agent团队协作、部门级中台
2028+	自主决策型组织（Adaptive Organization）	Agent自动生成报告、预算、策略

关键词：「从工具自动化 → 决策增强 → 组织智能演化」

协同办公Agentic AI 落地应用三个问题

- 如何为企业协同办公垂直场景建立可落地、可复现的Benchmark / Evaluation 框架?
- 建议的评测指标、数据集与流程（含样例权重与阈值）有哪些?
- 美国大厂 / 领先公司在“Agentic / 企业Agent 评测与实践”上的真实案例与可借鉴做法有哪些?

为什么需要专门的“企业协同办公 Agent” Benchmark?

企业协同办公场景（会议→任务→审批→知识检索）性质上是多模态、多步决策、强业务约束的复合任务：

- 单纯的NLP或摘要基准无法衡量 Agent 的执行正确性、合规、审计与商业价值。
- 需要把任务成功率 + 可信度/可审计性 + 业务ROI 三类能力纳入同一套评价体系。
- Salesforce、ServiceNow、Snowflake 等大厂也在为企业Agent设计专门的评测与治理工具/benchmark。

推荐的Benchmark框架

评测维度

功能性 (Task Success) — Agent 是否完成指定业务动作（任务创建、审批发起、发票匹配、入账触发等）。

准确性与事实性 (Factuality / Hallucination Rate) — 输出是否基于真实证据（RAG 源链接），生成误导/错误信息的比率。

端到端效率 (Automation & Time Savings) — 自动化率、人工参与度下降、审批或任务完成周期缩短。

可审计性与合规 (Traceability / Policy Compliance) — 每次动作是否有可检索日志/证据链、是否满足数据分类策略。

用户体验 (Human Eval / UX) — 人工评分（可用性、可接受性、信任度、误操作恢复成本）。

实践建议： 把“功能性 + 可审计性 + 事实性”作为首要门槛（安全/合规为硬约束），再用效率与体验指标评估商业价值。

具体指标（示例、可量化）

Task Success Rate (TSR) = 完成正确业务动作的次数 / 尝试次数。

（目标： $\geq 90\%$ for non-critical tasks; $\geq 99\%$ for finance approvals with human-in-loop）

Action Precision / Recall（比如：会议行动项抽取的 precision/recall） — 标注级评估。

目标： precision ≥ 0.85 , recall ≥ 0.80 （视场景调整）。

Hallucination Rate = 生成断言中未能在检索到的证据中找到支持的比例（用 LLM-as-judge + 人工抽样复核）。

目标： $\leq 5\%$ （高风险场景更低）。

Automation Rate = 自动完成无人工批准动作的比率（或半自动后人工确认前的自动建议转化率）。

目标：初期 20 - 40%，成熟后 60%+。

Mean Time to Fulfill (MTTF) / Approval Cycle Time — 与基线比较（如审批从 48h $\rightarrow$ 12h）。目标：缩短 $\geq 40\%$ 。

Audit Coverage = 操作产生的可检索日志事件数 / 总动作数。

目标：100%覆盖（企业必须）。

Business KPI Impact（如：节省人力小时数、提高任务完成率、提高销售跟进率等）——用财务模型转换为 ARR / NPV。

推荐数据集（公开 + 私有混合）

公开会议语料（用于会议纪要/行动项抽取）：AMI Meeting Corpus、ICSI Meeting Corpus、TCR / 新近会议摘要基准（可做转写/抽取评测）。这些是通用动作抽取与ASR/摘要评测的起点。

合成/增强数据：使用“LLM 合成 + 人工校审”生成带标签的会议→行动对（例如 FAME/多语种会议合成研究可参考）。

企业真实日志（核心）：审批流历史（表单、审批时序）、任务系统（创建/完成记录）、CRM 对话/邮件/通话记录（脱敏化）。这些用于端到端业务成功率与ROI评估（私有数据、必须合规处理）。

注释规范：Action item (who/what/by-when)、Approval decision (pass/reject, reason)、Entity linking to source documents、Confidence label（模型/人工）。

向量检索与事实验证语料：企业知识库导出（合同条款、SOP、财务政策）作为 RAG 源。Snowflake / Databricks 实践中常把这些作为“证据库”以减少幻觉。

评估流程（工程化 + 可复现）

构建测试套件（离线 dataset）：包含 N 个会议、M 个审批案例、K 条 CRM 对话，带标准标签（task, owner, deadline, evidence）。

离线自动化评测：跑模型/agent，在 sandbox 环境（无写权限）执行“dry-run”并记录输出（action, API calls, evidence pointers）。计算自动指标（TSR、precision/recall、hallucination rate via LLM-judge）。Salesforce 与 Snowflake 提倡“LLM-as-judge”作为规模化评估手段，但需混合人工抽样验证。

模拟执行（shadow/parallel run）：在真实系统并行记录 agent 的建议/动作，但不真正入库；与真实人工操作对比（差异分析、风险检测）。ServiceNow/Now Assist 与 Microsoft/Databricks 都提供类似的“evaluate then enable”流程。

小流量 A/B 或 Canary：对低风险流程（如会议纪要自动任务创建）做小范围上线，监控 KPI（自动率、人工回退率、用户满意度）。

红队 / 合规评估：对决策类 Agent 做 adversarial 测试（越权、数据泄露、错误指令）并验证审计链与回滚策略。Snowflake/ServiceNow 文档都强调治理与监控。

持续监控与数据回流：模型线上表现（drift、hallucination）纳入 MLOps/ModelOps（Databricks + MLflow 等）与可视化报警。Databricks/MLflow 在模型生命周期管理与监控方面是行业常见实践。

评测工具与自动化建议

LLM-as-Judge: 用强基线 LLM 对候选输出做“证据检验/打分”，再人工抽样复核（Snowflake / Snowflake Cortex & LLM-judged labels 的做法可借鉴）。

Agent Evaluation Dashboards: 参考 ServiceNow 的 AI Evaluation / AI Control Tower 能力（内建评估面板，适合 Virtual Agent）。

MLOps + Logging: Databricks + MLflow（模型版本、实验、监控）与 Snowflake 的数据治理/Unity Catalog 用于存证与上下文管理。

美国科技大厂与领先创业公司的实践案例（要点与可借鉴处）

Salesforce — Enterprise Agent Benchmark & Agentforce / Einstein GPT

要点： Salesforce AI Research 已发布面向企业工作流（text & voice）专用 benchmark，强调 agent 对复杂工作流的端到端能力与可信任性；产品化的 Einstein GPT / Agentforce 将自动生成任务、知识文章并能与 Service Cloud/Slack/CRM 深度集成。Salesforce 把“benchmarks + guardrails + models”作为研发到产品交付闭环。
可借鉴点： 专门针对企业工作流的基准集 + 内嵌证据链与可解释性。

ServiceNow — Now Assist / Virtual Agent + Agentic Evaluation

要点： ServiceNow 在平台中提供“AI Evaluation”/Agentic evaluation run 功能，用于对 Agentic workflow 在选定 dataset 上打分；并有 Process Mining/Performance Analytics 用于发现审批/协作瓶颈（评测前须先用 Process Mining 找目标流程）。
可借鉴点： 把流程挖掘与评测结合（先定位高价值流程，再跑bench）。

美国科技大厂与领先创业公司的实践案例（要点与可借鉴处）

Databricks — Agent Framework + Evaluation Notebook

要点： Databricks 提供 Agent 框架与示例 Notebook (build, deploy, evaluate retrieval agents)，并建议把 Agent 的“上下文 (memory)”与数据治理放在 Unity Catalog / Delta 表中，便于repeatable evaluation 与审计。

可借鉴点： 用Notebook/Job封装评测流程，结合 Unity Catalog 做数据与context治理。

Snowflake — Cortex / Cortex Agents / LLM-judged labels

要点： Snowflake 的 Cortex 提供 Search/Analyst/Agents 一体化方案，并在检索与评估中采用“LLM-judged labels”进行自动调参/打分；强调把向量检索、证据回溯与监控嵌入数据平台层。

可借鉴点： 把检索、评估与监控放到数据平台层，借助 LLM 做自动标签与评测加速。

示例：针对“会议→任务” Agent 参考Benchmark

数据集： AMI (100h) + 公司脱敏会议 200 次 + 合成人工标注 500 会议

标注项： 每条会议标注 action items (who, what, by-when)、议题、决策点、evidence span (transcript index / slide ref)

评价指标 & 权重 (总分 100 分)：

Action Extraction Precision/Recall — 30 分 (Precision 18, Recall 12)

Task Success (正确创建并映射任务到系统) — 25 分

Evidence Linking (是否给出支持句/文档) — 15 分

Hallucination Rate (低则高分) — 10 分

User Human Eval (5 分：可用性评分, 5 分：信任度) — 10 分

Audit Log Completeness (5 分) — 5 分

门槛： 整体 ≥ 75 分, 且 Action Extraction Precision ≥ 0.85 , Hallucination Rate ≤ 0.05 才允许进入 shadow-run。

评测流程： 离线自动评分 → LLM-as-judge 二次打分 → 抽样 10% 人工复核 → Shadow-run 2 周 → 小规模 Canary。

(上面方法融合了 Salesforce 的 enterprise-agent benchmark 思路, ServiceNow 的 evaluation-run 实践与 Snowflake 的 LLM-as-judge idea。)

6 步可执行的落地行动清单

面向技术/产品/数据团队：

确定高价值流程（用 Process Mining / 运营访谈锁定 3 个优先场景：例：会议→任务、报销审批、客户跟进）。
（借鉴 ServiceNow 做法）

准备评测数据集：导出历史日志（脱敏）、并补充 AMI/ICSI 作为通用会话基线；设计并启动 200 条内部注释任务（action item 标注）。

定义评测指标与门槛：采用上文样例权重，明确进入 shadow-run 阈值（精确率、幻觉率等）。


实现离线评测流水线：用 Databricks Notebook / MLflow 把模型推理、日志、评分统一编排（便于复现与版本控制）。

LLM-as-Judge + 抽样人工复核：用 Snowflake / 自有环境跑 LLM 打分以实现规模化评估，保留 10 - 20% 人工复审。

Shadow-run → Canary（灰度测试） → 全量部署：先并行记录建议（不落地）2 - 4 周，再做 5 - 10% 流量 Canary，监控 Audit & Drift 指标，直到安全合规门槛。

安全风险、失败模式与缓解建议

- 可靠性风险：多步任务完成率低（学术与企业测试多见），导致用户信任崩塌。缓解：分级部署（read-only → sandboxed actions → live actions）、强测试套件与回滚策略。
- 合规/隐私风险：agent 可访问敏感系统时，需要细粒度权限与审计链。缓解：权限白名单、操作签名、不可撤销日志。
- 经济风险：滥用 token/调用成本太高。缓解：本地/边缘轻量模型、mixed-precision、策略缓存与技能复用。
- 监管/伦理风险：自动化决策引发责任归属问题。缓解：人机混合审批、责任分类与 SLA。



董事会和法律/合规团队风险沟通

- 准备好“事故应对剧本”（agent 执行失误时的补救）：通知链、紧急停止按钮、回滚机制、可追溯日志。在平台上投入“可审计的 action 层”优先级高：若能同时保证执行能力与审计日志，能拿到大型企业客户。
- 与监管/内审一起定义“可接受自动化等级”（例如仅允许 agent 提案但需人工签署的任务）。

How businesses can build trust in implementing Agentic AI



Agentic AI如何真正“落地”到企业办公场景中建议

传统协同办公的逻辑是：“人—任务—系统”的线性协同 → 自动化流程（RPA、Bot）
而 **Agentic AI 落地的核心转向** 是：“智能体—场景—人”的循环智能协同 → 自主执行 + 情境理解 + 自我演化
落地建议：**以Agent为基本单元，重新设计企业的协同工作流、知识流与决策流。**

层面	战略目标	建议方向	海外示例案例
任务级落地	降低重复劳动、提升响应速度	建立“Task Agent”库，覆盖文档生成、会议纪要、审批建议、日报生成等	Salesforce Einstein Copilot
流程级落地	让流程具备自适应与学习能力	用LLM + Graph建模企业流程知识图谱，实现动态流程编排	ServiceNow GenAI Flow
场景级落地	智能协同、跨部门沟通优化	设计跨职能Agent协作空间 (Finance-Agent、HR-Agent、Sales-Agent)	Databricks Lakehouse AI Agent
知识级落地	让企业知识“流动起来”	构建企业知识中台 + Context Memory + 自演化问答系统	Snowflake Cortex Agent
决策级落地	管理层智能洞察与预测	将Agent嵌入BI/ERP数据流，实现可解释预测、建议生成	Microsoft Copilot for Dynamics 365

Agentic AI 协同办公场景Benchmark模型

评估维度	核心指标	测量方法	示例
智能水平 (Cognitive Capability)	自主性、记忆深度、 上下文适配	LLM Benchmark + 企业知识Context评测	e.g. Claude 3.5 Agent Eval
流程嵌入度 (Workflow Integration)	可嵌入率、 触发自动化比例	API触发率、 任务自动闭环率	Salesforce Einstein Copilot
协同效应 (Collaboration Synergy)	多Agent互动成功率	人-Agent + Agent-Agent对话质量	Slack + Salesforce 测试
价值贡献 (Business Impact)	节省时间、 人均产出增长	ROI测算、 任务周期缩短	金蝶智能协同平台试点数 据

从“系统数字化”到“组织智能化”

- 金蝶作为中国企业数字化生态核心，有机会成为「中国企业Agent化转型的基础设施运营商」。
- Agentic AI 将是企业办公的 第二条增长曲线，也是未来五年中国企业应用创新的最大机会带。

协同办公的未来，不是更高效的工具，而是更懂业务、能自我成长的Agent伙伴。真正的生产力跃升，将来自人机共智的企业生态系统。

企业的下一场竞争，不在于谁的系统更多、流程更全，而在于谁的“Agent生态”能更快学习业务、理解意图、执行任务。



2025全球创见者大会
GLOBAL CHANGEMAKERS CONFERENCE 2025

ขอบคุณ
Gracias 谢谢
感謝 Thanks
Terima kasih
Merci
آركش
Danke

David.Chiu 13539466559