


2026 大模型Agent 故障诊断深度分析报告

从 Observability Copilot 到自
治诊断 Agent —— 行业全景
与五大诊断方案解析

中兴通讯（ZTE）智能技术分析团队 | 日期：2026.05




2026 分水岭：跨越“自治执行”的临界点



高危警示：原生 LLM 的脆弱性

数据支撑：NetArena 基准测试表明，赋予无约束大模型集群生产环境执行权限，常导致清空数据库或切断核心路由等毁灭性次生灾害。纯黑盒操作已无法生存。

宏观驱动力：四维修模挤压下的 L4 自智网络演进



算力与技术

- 万字长文本 Trace 推理成本因 DeepSeek V4 (1.6T MoE) 等模型呈指数下降。
- 故障数据从单模态走向 Trace + Metric + Log 深度多模态融合。



政策与合规

- 欧盟 EU AI Act (2026.08 大限)：IT运维网络 Agent 被列为“高风险”，强制要求操作可逆与人类在环。纯黑盒操作被严格禁止。



行业角逐

- 竞争下沉至“硬件感知力”。华为主推 AEI 架构；思科将大模型直接整合进物理硬件管理。纯软件 SRE 失去微秒级透视优势。



客户诉求


- 电信客户付费意愿实质性转移：从“缩减告警噪音”转向“业务自愈挽回”与“SLA 违约规避”。

L4
自智网络

走向自治的武库：五大并行诊断方案




方案一：ReAct 与工具增强智能体



核心原理	摒弃一次性生成。通过 LLM 动态调用外部探针工具（如 nftables, vtysh）收集实况证据，基于回显决定下一步动作。
代表架构	Cisco Deep Research AI / SADE (Symptom-Aware Diagnostic Escalation) 框架。
关键局限	“迷失方向”。在极端复杂的长周期排障中，模型极易陷入工具调用死循环，最终耗尽 Token 预算。


方案二：知识图谱增强推理（KG-Enhanced Reasoning）



核心原理	将静态运维机理结构化为实体关系图谱。推理前抽取子图作为背景约束，强制大模型遵循物理现实逻辑。
代表架构	FDRKG-LLM / 中兴联通图谱诊断实践（辅助根因定位准确率 >95%）。
核心突破	超越纯 RAG 的文本检索，具备“发现隐性依赖”演绎能力，可定位 CMDB 漏记的阻断节点。
关键局限	异构数据对齐与高质量图谱的持续更新成本极高。

方案三：递归思维链（RoT）与 GRPO 强化微调

线性思维 (CoT)



递归试错回溯 (RoT)

核心原理

抛弃死板的 1-2-3 指令链。赋予模型探索死胡同同时主动回溯上游决策点的权力。利用 GRPO 算法对轻量级小模型进行推理策略强化学习。

代表架构

ThinkFL 模型 / DeepSeek V4/R1 架构底座。


核心突破

几十亿参数的小模型在故障逻辑推演上匹敌千亿参数通用大模型，端到端延迟从分钟级缩至秒级。

关键局限

极度依赖探针高保真时序数据。eBPF 采集若现数据乱序，将产生级联误判。

方案四：网络数字孪生（NDT）与故障树诱导



核心原理	面对不可逆物理变更（如端口 Shutdown），指令必须先 在 1:1 高清虚拟网络中进行无破坏模拟，验证无次生灾害后方可下发。
代表架构	Aether 验证框架 / 中兴智能运维孪生。
核心价值	解决大规模“AI Oops（系统瘫痪）”的终极防线，满足 EU AI Act 审计要求的唯一物理隔离解。
关键局限	算力消耗极大，数字与物理空间的微秒级状态同步（数据新鲜度）构成技术瓶颈。

方案五：多智能体协同（Multi-Agent Orchestration）



核心原理

废弃单中心大模型，将任务拆分给多职能 Agent。通过智能体间通信协议（A2A）直接谈判降级代价或诊断参数。

代表架构

中国移动“多级多智能体故障自愈” Catalyst / mABC 框架。

核心突破

终结跨部门工单推诿。跨域 Agent 直接商定 QoS 降级，全程耗时 < 1 秒。

关键局限

深层通信中，上下文频繁交换极易引发严重 Token 冗余膨胀，推升运算成本。

诊断范式综合对比矩阵

核心机制	核心突破	核心局限	算力成本
ReAct: 动态工具调用	异构探查极强	易陷死循环	
知识图谱: 神经符号约束	发现隐性依赖	异构对齐极贵	
RoT/GRPO: 试错与回溯	小模型匹敌千亿模型	乱序数据致命	
数字孪生: What-If 模拟	100% 免疫毁灭灾害	微秒同步瓶颈	
多智能体: 分布式协商	跨域处置 <1 秒	Token 极速膨胀	

2026 产业链全景：MCP 网关成为中游核心枢纽

上游：极限物理算力与互联底座

- Nvidia/昇腾集群。
- ClickHouse/VictoriaMetrics 高基数时序数据仓（毫秒级响应）。

中游：大模型基座与安全网关（重点关注）

- 基座：DeepSeek V4, Qwen 3, 中兴 Co-Sight。
- 关键枢纽：Bifrost 等 MCP Gateway。一次接口编写即可对接各种开源基座，专司身份验证、防注入与审计拦截。AIOps 安全拦截已成独立赛道。

下游：场景化交付与原子服务

- SOC/NOC 垂直场景应用，化身为光模块劣损预测、K8s OOM 排查等原子操作。

中兴通讯 AIR MAX 架构：硬件感知的全栈自控推理

Top Layer: Telco Service Agent

意图直驱下沉，越过传统 OSS，语言界面直达 5G 核心网网元下发配置。

Middle Layer: Co-Sight + 1+N 异构模型矩阵

1（通用大模型）：负责复杂意图分解。N（专用小模型）：负责海量特征处理与高频时序分析，动态蒸馏克服幻觉。

Base Layer: OEX 物理算力底座

核心壁垒：通过零线缆物理底座直接消减底层信号噪点。这是纯软件诊断系统难以逾越的物理护城河。



零信任执行盾：从“事后追溯”到“事前拦截”

Shield 1: 实体安全绑定

CMDB 资产库校验。所有 LLM 生成的动作对象，必须在备案资产中（防伪造资源攻击）。

Shield 2: MCP 白名单与 JSON 约束

严禁模型创造代码片段执行。仅允许输出标准化 JSON 载荷以触发原生原子操作，彻底杜绝越界破坏。

Shield 3: 孪生验证与人类在环

遇到高危变更或孪生验证失败，系统立即挂起并自动流转至人类专家审批节点。

Telco Agent

核心承诺：复杂网元故障场景下，隔离决策准确率 >95%，跨网元恢复响应降至秒级。

双线落地实践：5G-A 核心网与算网融合



5G-A/6G 通信网络全流程自定界

- **场景：**承载网链路劣化引发小区掉话。
- **动作：**Telco Service Agent 捕捉告警，利用 FTI（故障树诱导）与知识图谱，倒推至特定传输单板隐性衰减，重构 ASN.1 协议解析。
- **KPI：**告警自动压缩处理闭环率近 **40%**；光模块隐患预测准确率达 **75%**。



算网融合基础设施根因 Copilot

- **场景：**K8s 微服务锁表与 GPU 任务中断。
- **动作：**基于 ThinkFL 模型 RoT 递归探索，遇盲区时调用 Text2SQL 向 ClickHouse 重构查询并获取火焰图。
- **KPI：**定位深度超越一线 SRE 限制；无意义日志排查耗时骤降 **>50%**。

2026-2028 演进路线图与战略收官



大模型并未消灭网络工程师，而是将其强制晋升为系统的“策略边界设计师”与“高阶异常监督员”。
停止对死板监控大屏的投资，立即转向结构化配置资产与 MCP 安全网关建设。