




大模型推理的范式转移： 从显性思维链到高效智能


探索自适应蒸馏、隐式推理空间与 GRPO 强化学习的新前沿

现状与瓶颈：思维链（CoT）的“不可能三角”



核心洞察：我们需要打破这一瓶颈的三种新路径——更聪明的教学（ACoTD）、更直觉的思考（Implicit CoT）、更强的自我进化（GRPO）。

路径一：自适应思维链蒸馏（ACoTD）——因材施教的艺术



核心理念：传统的蒸馏是“一刀切”的。ACoTD 根据学生模型对原始问题的掌握程度，动态定制教学策略。通过自适应采样，避免了简单问题的冗余计算，集中算力攻克复杂逻辑。

ACoTD 实战数据：精准填补小模型的能力短板


简单问题策略

学生模型只需简短确认即可掌握。避免过长推理带来的噪声。

困难问题策略

学生模型获得所需的详细逻辑路径，防止逻辑漂移。

动态调整不仅节省了 Token，更带来了 20% 的准确率提升。




路径二：隐式思维链 —— 从“显性慢思考” 到 “隐性快直觉”

Explicit CoT (显性)



技术核心：将推理过程从‘语言生成空间’压缩至‘连续向量空间’。如同人类直觉，无需默念步骤即可得出 $2 \times 2 = 4$ 。


Implicit CoT (隐性)



水平方向展开 (Language Space) - 慢且昂贵

垂直方向变换 (Latent Space) - 快且零 Token

CODI 与 TwT: 将思维压缩进连续空间



CODI 框架

将自然语言 CoT 压缩为连续向量表示。教师模型生成显性 Token，学生模型通过对齐隐层状态来模仿推理效果。

TwT (Thinking without Tokens)


习惯性推理蒸馏。通过多教师指导 (Multi-teachers' guidance)，让模型养成“不说话但会思考”的习惯。

性能指标 (GSM8k)

- 压缩率: **3.1x**
- 准确率提升: **+28.2%**
- 速度: GPT-2 规模即可达到 SOTA

路径三：GRPO —— 摆脱对昂贵标注数据的依赖

DeepSeek-R1 背后的强化学习引擎



GRPO: 去除 Value Model, 大幅降低资源需求

GRPO（群体相对策略优化）的核心创新

GRPO 的核心创新在于不再需要单独的价值模型 (Value Model) 来评估每一步。它对同一个 Prompt 采样一组输出，通过计算组内相对优势 (Advantage) 来优化策略。这使得普通显卡也能训练推理模型。

奖励机制的设计：代码验证与相对优势

$$A_i = \frac{r_i - \text{mean}(r)}{\text{std}(r)}$$

相对优势 (Advantage) ← A_i

← r_i 单次采样得分

← $\text{mean}(r)$ 组内平均表现 (Baseline)

← $\text{std}(r)$

无需人类标注的验证逻辑 (The 'No-Label' Magic)

✓✗ 准确性奖励 (Accuracy)

答案是否正确？

(Binary: 1.0 / 0.0)

适用于数学、代码编译。

<> 格式奖励 (Format)

是否遵循思考标签？

Example: `<think> ... </think>`

强制模型内化思考过程。


引入 KL 散度 (KL Divergence) 防止模型在强化学习过程中偏离原始语言分布，确保语言的流畅性。

实战案例：ThinkFL —— 当 GRPO 遇上复杂系统运维



Generic LLM

通用模型：受限于僵化的 SOP，推理昂贵，难以定位根因。



ThinkFL


ThinkFL：轻量级模型 + 强化微调（RFT）。摆脱僵化流程，具备自我反思与探索能力。

应用场景：微服务故障定位（Failure Localization）。

痛点：现代系统极其复杂，故障定位如大海捞针。

解决方案：利用 GRPO 进行多阶段训练，使 <10B 参数的小模型在特定领域超越 GPT-4。

ThinkFL 架构：递归思维与多阶段进化



三阶段训练流水线 (Training Pipeline)


- 1. Format-Aware Policy Priming:**
规范工具使用格式。
- 2. Guided Exploration Augmentation:**
鼓励模型探索不同的诊断路径。
- 3. Rank-Oriented Refinement:**
优化最终根因排序的准确性。

效果验证：速度与准确率的双重飞跃

定位延迟 (Latency)



定位准确率 (Accuracy)



核心洞察：通过 RFT（强化微调），小模型学会了在特定领域内“像专家一样思考”，无需大模型的通用冗余知识，实现了效率与效果的完美平衡。

总结：大模型推理的新范式对比

范式 (Paradigm)	核心特征 (Key Feature)	成本与速度 (Cost/Speed)	最佳场景 (Use Case)
传统 CoT	显性推理，Token 堆叠	高成本，慢	通用复杂任务
ACoTD (路径一)	自适应长短，因材施教	中等成本，效率提升	师生模型蒸馏
Implicit / CODI (路径二)	隐性直觉，无 Token 推理	极低延迟，极快	高频实时交互
GRPO / ThinkFL (路径三)	自我进化，无 Value Model	训练资源低，推理快	特定领域（数学/运维）深度优化

结语：通往高效智能之路

Internalization (内化)


System 2 的慢思考正在**内化**为 System 1 的**快直觉**。

Democratization (普惠)

算力不再是壁垒。通过 GRPO 和**高效蒸馏**，端侧小模型将具备**专家级推理力**。

Data Strategy (数据)

只要能定义“**验证函数**”，模型就能**自我进化**，无需人类介入。



参考文献 (References)

1. "Adaptive Chain-of-Thought Distillation Based on LLM Performance on Original Problems (2025)" - ACoTD
2. CODI: Compressing Chain-of-Thought into Continuous Space via Self-Distillation (2025)
3. Implicit Chain of Thought Reasoning via Knowledge Distillation (2023)
4. TwT: Thinking without Tokens by Habitual Reasoning Distillation
5. DeepSeekMath: Pushing the Limits of Mathematical Reasoning (GRPO)
6. ThinkFL: Self-Refining Failure Localization for Microservice Systems via Reinforcement Fine-Tuning

